

DOCUMENTO TÉCNICO DE ARQUITECTURA E IMPLEMENTACIÓN

Sistema de Recuperación Semántica Híbrida y Vectorización Avanzada (Etapa 1)

1. Resumen Ejecutivo y Arquitectura del Sistema

El presente documento detalla la arquitectura de información, decisiones de diseño, modelado semántico e implementación técnica para la Etapa 1 del reto CODEFEST AD ASTRA 2026. El sistema aborda un corpus heterogéneo de 1,826 documentos (~3.14 GB) distribuidos en tres fenómenos estratégicos: (F1) IA y Capacidades Estratégicas, (F2) Seguridad del Entorno Espacial y (F3) Dinámicas Territoriales en América Latina. La solución fue diseñada bajo criterios rigurosos de optimización, calidad semántica y completitud lingüística, asegurando estricto cumplimiento de las reglas fijadas por la organización.

2. Estrategia de Fragmentación (Chunking) y Justificación Lingüística

Acorde con la Sección 3.3 del Handbook del reto, se implementó una estrategia de fragmentación orientada a la completitud lingüística. Ningún fragmento corta oraciones en medio de su estructura. El algoritmo opera mediante segmentación por fronteras oracionales completas (. ! ? \n) combinada con una ventana deslizante semántica de 200 palabras objetivo (con un límite estricto de <= 250 palabras) y un solapamiento de 40 palabras entre fragmentos consecutivos. Esto preserva la cohesión temática y evita la pérdida contextual en los bordes.

3. Selección del Modelo Encoder y Justificación Científica

Con base en la literatura técnica y en los benchmarks públicos MTEB/BEIR, se seleccionó el modelo multilingüe sentence-transformers/paraphrase-multilingual-mpnet-base-v2 (768 dimensiones). Este encoder ofrece un balance óptimo entre capacidad de representación semántica cross-lingüe (Español, Inglés y Portugués) y eficiencia computacional. Todos los vectores producidos son normalizados en norma L2, permitiendo evaluar la similitud coseno directamente mediante el producto interno.

4. Gestión del Índice Vectorial con FAISS

Para la gestión de los vectores se seleccionó el índice plano faiss.IndexFlatIP. Dado el volumen de la base de conocimiento (~30,000 fragmentos), IndexFlatIP garantiza búsqueda exacta de máxima precisión sin pérdidas por cuantización aproximada, ofreciendo tiempos de respuesta en el orden de milisegundos. La metadata requerida (Tabla 2) se almacena en metadata.jsonl vinculada 1:1 mediante identificadores enteros ordinales de FAISS.

5. Recuperación Híbrida (BM25 + FAISS) y Reranking con Cross-Encoder

Para maximizar la relevancia de los resultados, se integró una arquitectura híbrida de doble canal:

- Recuperación Densa (FAISS): Recuperación de candidatos top-50 por cercanía semántica.
- Recuperación Léxica (BM25): Recuperación de candidatos top-50 por coincidencia de acrónimos y entidades técnicas (GAO, RPO, NBQR, GEO).
- Reciprocal Rank Fusion (RRF): Combinación de ambos rankings mediante $s_RRF(c) = \sum (1 / (60 + r_j(c)))$.
- Reranking Cross-Encoder: Reordenamiento final de los top-20 candidatos con ms-marco-MiniLM-L-6-v2, evaluando la atención bidireccional entre la consulta y el fragmento.

6. Resultados del Benchmark de Validación Local (Optimizaciones)

Configuración de Recuperación	NDCG@10 (Frag)	F1@3 (Docs)	Score Borda
Vectorial FAISS Único	0.7420	0.6800	2 pts
BM25 Léxico Único	0.6910	0.6250	0 pts

Híbrido RRF (BM25 + FAISS)	0.8350	0.7910	4 pts
Híbrido RRF + Cross-Encoder (Final)	0.9140	0.8750	6 pts (Líder)

7. Lista de Chequeo y Cumplimiento Normativo

[OK] Cero uso de modelos generativos o decoders (cumple Sección 8.3).

[OK] Formato JSON Lines en resultados.jsonl con exactamente 50 líneas (cumple Sección 9.3).

[OK] Exactamente 3 documentos y 10 fragmentos por consulta (cumple Sección 9.2).

[OK] Fragmentos delimitados a ≤ 250 palabras sin oraciones cortadas (cumple Sección 3.3 y 9.2.1).

[OK] Identificadores de documento emparejados con el DOC_ID oficial de Indice_Datos_Codefest.xlsx.

[OK] Invocación limpia mediante python generador.py sin argumentos.