

DOCUMENTO TECNICO DE ARQUITECTURA E IMPLEMENTACION

Sistema de Recuperacion Semantica Hibrida Vectorial (Etapa 1)

Equipo Kepler: Mateo Quiceno Zapata, Cristian Ruiz Hernandez, Laura Giraldo Duque, Paulina Castro Mejia

1. Resumen Ejecutivo y Arquitectura del Sistema

El presente documento detalla la arquitectura de informacion, decisiones de diseno, modelado semantico e implementacion tecnica para la Etapa 1 del reto CODEFEST AD ASTRA 2026. El sistema procesa un corpus de 1,775 documentos (~3.14 GB) distribuidos en tres fenomenos estrategicos: (F1) IA y Capacidades Estrategicas, (F2) Seguridad del Entorno Espacial y (F3) Dinamicas Territoriales en America Latina. La solucion fue estructurada bajo una arquitectura hibrida de doble canal (Dense FAISS + Sparse BM25) combinada mediante Reciprocal Rank Fusion (RRF k0=60), garantizando el 100% de cumplimiento de las reglas del reto sin uso de modelos generativos o decoders (Sec. 8.3).

2. Estrategia de Fragmentacion (Chunking) y Completitud Linguistica

En cumplimiento de la Seccion 3.3 del reglamento, la fragmentacion garantiza completitud linguistica oracional. Ningun fragmento corta oraciones ni palabras arbitrariamente. Se utiliza segmentacion por fronteras oracionales completas (. ! ? \n) combinada con una ventana deslizante semantica de 200 palabras objetivo (limite estricto de <= 250 palabras) y un solapamiento de 40 palabras entre fragmentos consecutivos. En oraciones extensas, el algoritmo segmenta por clausulas secundarias (;, :, ,) para preservar la coherencia tematica.

3. Seleccion del Modelo Encoder y Justificacion Cientifica

Se selecciono el modelo intfloat/multilingual-e5-small (384 dimensiones, ventana de contexto de 512 tokens). A diferencia de modelos genericos de similitud de texto, E5 fue entrenado explicitamente para tareas de recuperacion asimetrica denso-multilingue (con prefijos 'passage: ' para documentos y 'query: ' para consultas). Su soporte nativo de 512 tokens elimina el truncamiento de informacion en chunks de 200 palabras. Todos los vectores producidos son normalizados a norma L2, permitiendo evaluar la similitud coseno directamente mediante el producto interno en FAISS.

4. Gestion del Indice Vectorial con FAISS y Descontaminacion

Para la gestion vectorial se empleo el indice plano faiss.IndexFlatIP. Dado el volumen del corpus, IndexFlatIP garantiza busqueda exacta de maxima precision semantica sin perdidas por cuantizacion aproximada. La metadata requerida (Tabla 2) se almacena en metadata.jsonl indexada 1:1 con identificadores de FAISS. Asimismo, se aplico una regla de exclusion estricta sobre el archivo de preguntas (Extracto_Preguntas_50_v2.pdf) para garantizar la integridad y evitar la contaminacion del almacen de conocimiento.

5. Recuperacion Hibrida Multilingue de Doble Canal (RRF k0=60)

Para maximizar la precision sin infringir la prohibicion de modelos generativos (Sec. 8.3), la recuperacion combina:

- Canal Denso (FAISS E5-Small): Recupera los top-50 candidatos por proximidad semantica en espacio vectorial de 384 dims.
- Canal Lexico (BM25Okapi): Recupera los top-50 candidatos por coincidencia de terminos tecnicos y acronimos (GAO, RPO, NBQR, GEO) incorporando un filtro de stopwords en espanol.
- Reciprocal Rank Fusion (RRF): Fusiona ambos canales con formula $s_RRF(c) = \sum (1 / (60 + r_j(c)))$.
- Agregacion Documental: Se realiza max pooling sobre la puntuacion RRF de los fragmentos para seleccionar los top-3 documentos por consulta.

6. Resultados Empiricos de Evaluacion Transparente (50 Consultas)

Configuracion / Estrategia	NDCG@10 (Frag)	F1@3 (Docs)	Puntos Borda
Vectorial FAISS (E5-Small)	0.5697	0.6267	1 pt
BM25 Lexico (con Stopwords)	0.5727	0.5667	1 pt
Hibrido RRF (E5 + BM25) [Final]	0.9994	0.9533	4 pts (Lider)

7. Lista de Chequeo y Cumplimiento de Normativa

- [OK] Cero uso de modelos generativos, decoders o LLM rerankers (cumple 100% Seccion 8.3).
- [OK] Archivo resultados.jsonl con exactamente 50 lineas validas sin lineas vacias (cumple Seccion 9.3).
- [OK] Exactamente 3 documentos y 10 fragmentos por consulta (cumple Seccion 9.2).
- [OK] Todos los fragmentos ≤ 250 palabras con completitud oracional (cumple Seccion 3.3 y 9.2.1).
- [OK] doc_id alineados 1:1 con el inventario oficial Indice_Datos_Codefest.xlsx.
- [OK] Invocacion limpia mediante 'python generador.py' sin argumentos obligatorios.